

# Восстановление матрицы корреспонденции по потокам

## Содержание

|          |                                                                                                       |          |
|----------|-------------------------------------------------------------------------------------------------------|----------|
| <b>1</b> | <b>Используемые обозначения</b>                                                                       | <b>2</b> |
| <b>2</b> | <b>Постановка задачи двухуровневой оптимизации</b>                                                    | <b>2</b> |
| <b>3</b> | <b>Численный алгоритм</b>                                                                             | <b>3</b> |
| 3.1      | Модель Бэкмана . . . . .                                                                              | 3        |
| 3.2      | Метод Франка—Вульфа . . . . .                                                                         | 3        |
| 3.3      | Зеркальный спуск с проекцией на пространство матриц корреспонденций в энтропийной геометрии . . . . . | 3        |
| 3.3.1    | Почему именно KL-геометрия для зеркального спуска . . . . .                                           | 4        |
| 3.3.2    | Энтропийный зеркальный шаг (мультипликативное обновление) . . .                                       | 4        |
| 3.3.3    | Проекция на маргиналии (IPF / iterative proportional fitting) . . . . .                               | 4        |
| 3.3.4    | Выбор шага: бэктрекинг . . . . .                                                                      | 5        |
| 3.4      | Расчет градиента потоков по матрице корреспонденции . . . . .                                         | 5        |
| <b>4</b> | <b>Генерация синтетических наблюдений потоков</b>                                                     | <b>5</b> |
| 4.1      | Генерация референсных значений для функционала оптимизации . . . . .                                  | 5        |
| 4.2      | Выбор начального приближения для зеркального спуска . . . . .                                         | 6        |
| <b>5</b> | <b>Численные эксперименты</b>                                                                         | <b>6</b> |
| 5.1      | Гиперпараметры алгоритма . . . . .                                                                    | 6        |
| 5.2      | Референсная матрица $D_{ref}$ совпадает с $D_{true}$ . . . . .                                        | 6        |
| 5.2.1    | Вариация количества наблюдаемых потоков на случайных рёбрах . .                                       | 6        |
| 5.2.2    | Вариация выбора конкретных рёбер для лучшего качества восстановления . . . . .                        | 6        |
| 5.3      | Референсная матрица $D_{ref}$ не совпадает с $D_{true}$ . . . . .                                     | 6        |
| 5.3.1    | Топ 10% наблюдаемых рёбер . . . . .                                                                   | 6        |
| 5.3.2    | Вариация выбора топ $p$ рёбер для лучшего качества восстановления .                                   | 6        |
| 5.4      | Сравнение с вундервафлей . . . . .                                                                    | 6        |

Илья Забара<sup>1</sup>, Евгений Ильин<sup>2</sup>, Николай Моргунов<sup>1</sup>, Леонид Переверзин<sup>3</sup>

<sup>1</sup> МФТИ, ФПМИ, М05-404г

<sup>2</sup> МФТИ, ФПМИ, М05-401в

<sup>3</sup> МФТИ, ФПМИ, М05-401а

Ставится bi-level задача о восстановлении матрицы корреспонденции по наблюдаемым потокам на ребрах транспортной сети. Приводится численный метод решения задачи оптимизации, основанный на методе зеркального спуска с проекциями на множество матриц, удовлетворяющих маргиналиям. Критерием качества восстановления матрицы корреспонденции является то, насколько хорошо она восстанавливает потоки на ребрах по равновесной модели Бэкмана. Приводится небольшое исследование качества восстановления матрицы

в зависимости от количества наблюдаемых потоков на рёбрах (от количества датчиков), а так же от положения датчиков на графе.

---

## 1 Используемые обозначения

Далее в тексте термины “OD-матрица”, “матрица спроса” и “матрица корреспонденции” обозначают одно и то же.

Транспортная сеть моделируется ориентированным графом  $G = (V, E)$  на  $|V| = n$  вершинах (зоны совпадают с вершинами), с числом рёбер  $|E| = m$  из данных сети. Используются следующие обозначения:

- $n$  — число зон (в эксперименте каждая зона соответствует вершине графа).
- $m$  — число рёбер.
- $D \in \mathbb{R}_+^{n \times n}$  — OD-матрица спроса,  $D_{ij} \geq 0, D_{ii} = 0$ .
- Маргиналии (исходящие/входящие):

$$L_i = \sum_{j=1}^n D_{ij}, \quad W_j = \sum_{i=1}^n D_{ij}.$$

- Вектор потоков на рёбрах:  $f \in \mathbb{R}_+^m$ .
- Маска наблюдений потоков:  $M \in \{0, 1\}^m$ ,  $M_e = 1$  означает, что поток на ребре  $e$  наблюдается. Поэлементное умножение обозначим  $\odot$ .

Множество допустимых OD-матриц с фиксированными маргиналиями:

$$\mathcal{D}(L, W) = \{D \in \mathbb{R}_+^{n \times n} : D\mathbf{1} = L, D^\top \mathbf{1} = W, D_{ii} = 0\}.$$


---

Каждому ребру  $e \in E$  сопоставляется **стоимость ребра** (далее используется используется BPR):

$$t_e(x_e) = t_e^0 \left( 1 + \alpha_e \left( \frac{x_e}{c_e} \right)^{\beta_e} \right),$$

где -  $x_e$  — поток на ребре  $e$ , -  $c_e > 0$  — пропускная способность, -  $t_e^0 > 0$  — время свободного проезда, -  $\alpha_e = 0.15$ ,  $\beta_e = 4$  (в эксперименте одинаковы для всех рёбер).

---

## 2 Постановка задачи двухуровневой оптимизации

Ищется  $D \in \mathcal{D}(L, W)$ , минимизирующая расхождение модельных и наблюдаемых потоков на наблюдаемых рёбрах, плюс L1-регуляризация:

$$\min_{D \in \mathcal{D}(L, W)} \underbrace{\frac{1}{2} \|M \odot (f(D) - \hat{f})\|_2^2}_{\text{data term}} + \lambda \underbrace{\|D - \hat{D}\|_1}_{\text{regularizer}},$$

где  $\lambda \geq 0$  — вес регуляризации,  $\hat{f}$  — экспериментальные значения потоков,  $\hat{D}$  — априорная матрица корреспонденции (может быть получена по модели или экспериментально),  $f(D)$  — решение задачи Бэкмана о равновесном распределении нагрузки на транспортную сеть. В синтетическом эксперименте из `main_11.py` берут  $\hat{D} = D_{\text{true}}$  (то есть штрафуют отклонение от известной «истины», чтобы проверить работоспособность метода).

---

### 3 Численный алгоритм

#### 3.1 Модель Бэкмана

Для фиксированного спроса  $D$  потоки  $f(D)$  определяются как решение задачи равновесного назначения (Wardrop UE), которая в случае с приведённой  $t_e(f)$ :

$$\min_{f \in \mathcal{F}(D)} \Phi(f) = \sum_{e \in E} \int_0^{f_e} t_e(s) ds,$$

где  $\mathcal{F}(D)$  — множество потоков, реализуемых некоторым разбиением спроса  $D$  по путям (стандартные ограничения сохранения потоков/спроса).

Градиент потенциала по потокам имеет простой вид:

$$\nabla_f \Phi(f) = t(f) \in \mathbb{R}^m, \quad [t(f)]_e = t_e(f_e).$$

#### 3.2 Метод Франка—Вульфа

1. Инициализация:  $f^{(0)}$  = распределение потоков по free flow time.
2. На итерации  $k$ :
  - вычисляются текущие времена  $t^{(k)} = t(f^{(k)})$ ;
  - решается линейная подзадача FW

$$y^{(k)} \in \arg \min_{y \in \mathcal{F}(D)} \langle t^{(k)}, y \rangle,$$

что можно переформулировать как “для каждого origin  $o$  весь спрос  $D_o$  отправляется по кратчайшим путям (по весам  $t^{(k)}$ ) к каждому destination  $d$ ”

- обновления состояния:

$$f^{(k+1)} = (1 - \gamma_k) f^{(k)} + \gamma_k y^{(k)}, \quad \gamma_k = \frac{2}{k+2}.$$

Остановка основана на относительном разрыве (диагностике FW):

$$\text{rgap} = \frac{|\langle f^{(k)}, t(f^{(k)}) \rangle - \text{SP}(t^{(k)}, D)|}{\max(\langle f^{(k)}, t(f^{(k)}) \rangle, 10^{-12})},$$

где  $\text{SP}(t^{(k)}, D) = \sum_{o,d} D_{od} \text{dist}_o^{(k)}(d)$  — суммарная стоимость кратчайших путей при весах  $t^{(k)}$ .

Итоговая аппроксимация равновесного потока:

$$f(D) \approx f^{(K)}.$$

#### 3.3 Зеркальный спуск с проекцией на пространство матриц корреспонденций в энтропийной геометрии

Оптимизация ведётся на множестве  $\mathcal{D}(L, W)$ , а ограничение по маргиналиям реализуется через **энтропийную геометрию**: зеркальный шаг делается в дивергенции Кульбака—Лейблера (KL/Bregman). Важно: KL здесь — это **геометрия прокс-шага/проекции**, а не отдельная регуляризация в функционале (регуляризатор L1, см. раздел 2).

### 3.3.1 Почему именно KL-геометрия для зеркального спуска

Переменная  $D$  должна оставаться **неотрицательной** и одновременно удовлетворять **линейным ограничениям на маргиналии**. Для таких задач (положительный ортант / симплексоподобные множества и транспортные планы) энтропийная геометрия является естественным выбором по двум причинам:

#### 1) Неотрицательность:

Энтропийный зеркальный шаг (exponentiated gradient) имеет вид  $D \mapsto D \odot \exp(-\eta G)$  и сохраняет  $D_{ij} \geq 0$  (в отличие от обычного аддитивного шага  $D - \eta G$ , который легко даёт отрицательные значения и требует дополнительных хаков).

#### 2) Проекция на маргиналии вычисляется эффективно:

KL-проекция на множество матриц с фиксированными суммами строк/столбцов сводится к IPF (попеременное масштабирование строк/столбцов). Евклидова проекция на то же множество, как правило, существенно дороже (это отдельная квадратичная задача с большим числом ограничений) и хуже сочетается с требованием неотрицательности.

Формально, зеркальный шаг можно понимать как решение прокс-подзадачи

$$D^{(k+1)} \in \arg \min_{D \in \mathcal{D}(L, W)} \left\{ \langle G^{(k)}, D \rangle + \frac{1}{\eta_k} \text{KL}(D \| D^{(k)}) \right\},$$

то есть мы “минимально” (в KL-смысле) меняем  $D^{(k)}$ , чтобы спуститься по (суб)градиенту и остаться в допустимом множестве.

### 3.3.2 Энтропийный зеркальный шаг (мультипликативное обновление)

Пусть  $G^{(k)} \in \partial_D \mathcal{L}(D^{(k)})$  — (приближённый) градиент/субградиент на итерации  $k$  и  $\eta_k > 0$  — шаг. Для L1-слагаемого можно взять субградиент

$$\partial_D \|D - \hat{D}\|_1 = \text{sign}(D - \hat{D})$$

(с нулями на диагонали).

Тогда энтропийное зеркальное обновление (exponentiated gradient) имеет поэлементный вид

$$\tilde{D}_{ij}^{(k+1)} = D_{ij}^{(k)} \exp(-\eta_k G_{ij}^{(k)}), \quad i \neq j,$$

и  $\tilde{D}_{ii}^{(k+1)} = 0$ .

### 3.3.3 Проекция на маргиналии (IPF / iterative proportional fitting)

После мультипликативного шага выполняется та же проекция на  $\mathcal{D}(L, W)$  в KL-метрике, которая для матриц с фиксированными маргиналиями реализуется как IPF (попеременное масштабирование строк и столбцов):

Инициализация:  $D \leftarrow \tilde{D}$ ,  $D_{ii} = 0$ .

Далее повторять  $T$  раз: 1) масштабирование строк:

$$D_{ij} \leftarrow D_{ij} \cdot \frac{L_i}{\sum_j D_{ij}},$$

2) масштабирование столбцов:

$$D_{ij} \leftarrow D_{ij} \cdot \frac{W_j}{\sum_i D_{ij}},$$

и после каждого шага обнулять диагональ.

Результат принимается как  $D^{(k+1)}$ .

### 3.3.4 Выбор шага: бэктрекинг

Шаг  $\eta_k$  выбирается бэктрекингом: стартуя с некоторого  $\eta_0$ , уменьшаем шаг  $\eta \leftarrow \beta\eta$  (где  $\beta \in (0, 1)$ ), пока не выполнится убывание цели

$$\mathcal{L}(D_{\text{cand}}) < \mathcal{L}(D^{(k)}) - \varepsilon_{\text{imp}}.$$

## 3.4 Расчет градиента потоков по матрице корреспонденции

Обозначим невязку на наблюдаемых рёбрах:

$$r(D) = M \odot (f(D) - \hat{f}) \in \mathbb{R}^m.$$

Тогда градиент data term выражается через Якобиан

$$J(D) = \frac{\partial f(D)}{\partial \text{vec}(D)} \in \mathbb{R}^{m \times n^2} : \quad \nabla_D \frac{1}{2} \|r(D)\|_2^2 = \text{unvec}(J(D)^\top r(D)).$$

Мы будем приближать  $J(D)$  при помощи рекурсивной формулы, которая следует из алгоритма решения задачи Бэкмана – метода Франк-Вульфа.

При фиксированных весах  $t^{(k)}$  нагрузка на каждой итерации метода линейна по  $D$  (так как решается задача ЛП на множестве):

$$y^{(k)} = A(t^{(k)}) \text{vec}(D),$$

где матрица маршрутизации  $A(t^{(k)})$  имеет элементы

$$[A(t^{(k)})]_{e,(o,d)} = \begin{cases} 1, & \text{если ребро } e \text{ лежит на выбранном кратчайшем пути } o \rightarrow d \text{ при весах } t^{(k)}, \\ 0, & \text{иначе.} \end{cases}$$

Если рассматривать веса  $t^{(k)}$  как «замороженные» (straight-through приближение), то Якобиан FW-итераций удовлетворяет рекурсии

$$\begin{aligned} G^{(0)} &= 0, & G^{(k+1)} &= (1 - \gamma_k)G^{(k)} + \gamma_k A(t^{(k)}), \\ J(D) &\approx G^{(K)}, & \nabla_D \frac{1}{2} \|r\|^2 &\approx \text{unvec}((G^{(K)})^\top r). \end{aligned}$$

Замечание: тако вывод имеет место быть, если при заданной нагрузке  $t_e(f(D^k))$  при всех  $k$  не существует двух кратчайших путей на графе сети (то есть с одинаковой стоимостью). Если такое всё же имеет место, то функция становится не дифференцируемой. Все же предполагается, что вектор, получаемый до заданному алгоритму является элементов субдифференциала даже в такой точке.

## 4 Генерация синтетических наблюдений потоков

Пусть задана «истинная» OD-матрица  $D_{\text{true}}$ .

### 4.1 Генерация референсных значений для функционала оптимизации

$$\hat{f} = f(D_{\text{true}}), \quad \hat{D} = \text{proj}(D_{\text{true}} * (1 + \xi)),$$

где  $\xi$  – некоторая случайная матрица, моделирующая шум в данных или неточность модели, по которой строится референс  $\hat{D}$ , а  $\text{proj}(\cdot)$  – проекция на маргиналии.

## 4.2 Выбор начального приближения для зеркального спуска

Стартовая точка  $D^{(0)}$  строится из референса  $D_{\text{ref}}$  через SVD и эвристическую модификацию сингулярных значений. Это сделано с целью контролируемого изменения точности начального приближения (это удобно для проведения экспериментов).

$$D_{\text{ref}} = U \text{diag}(\sigma) V^\top, \quad \tilde{D} = U \text{diag}(\tilde{\sigma}) V^\top,$$

где  $\tilde{\sigma}$  получается из  $\sigma$  некоторой модификацией (в экспериментах заменяется главное сингулярное число).

Далее  $\tilde{D}$  приводится в допустимое множество:

$$D^{(0)} = \Pi_{\mathcal{D}(L,W)}^{\text{KL}}(\max(\tilde{D}, 0)),$$

то есть выполняется проекция на заданные маргиналии  $(L, W)$  методом IPF с обнулением диагонали.

## 5 Численные эксперименты

### 5.1 Гиперпараметры алгоритма

- **Наблюдения потоков:** доля наблюдаемых рёбер  $p$ ; сид генерации маски; уровень шума  $\sigma$  и сид шума.
- **Референс и маргиналии:** уровень шума  $\sigma_{\text{ref}}$  (если используется); флаг «сохранить истинные маргиналии» (IPF-проекция  $D_{\text{ref}}$  на  $(L_{\text{true}}, W_{\text{true}})$ ).
- **Регуляризация:** вес  $\lambda$  у L1-регуляризатора  $\|D - D_{\text{true}}\|_1$  (в большинстве запусков используется  $\lambda = 5 \cdot 10^2$ ).
- **FW (Beckmann, hard):** максимум итераций  $K = 200$ ; критерий остановки  $\text{rgar} \leq 10^{-3}$ ; убывающий шаг  $\gamma_k = 2/(k + 2)$ .
- **Зеркальный спуск:** число внешних итераций (используется разное кол-во); максимум итераций бектрекинга 50; IPF-проекция  $T = 30$  внутренних итераций.

### 5.2 Референсная матрица $D_{\text{ref}}$ совпадает с $D_{\text{true}}$

#### 5.2.1 Вариация количества наблюдаемых потоков на случайных рёбрах

#### 5.2.2 Вариация выбора конкретных рёбер для лучшего качества восстановления

### 5.3 Референсная матрица $D_{\text{ref}}$ не совпадает с $D_{\text{true}}$

Референсная матрица  $D_{\text{ref}}$  зашумлена на 20%.

#### 5.3.1 Топ 10% наблюдаемых рёбер

#### 5.3.2 Вариация выбора топ $p$ рёбер для лучшего качества восстановления

### 5.4 Сравнение с вундервафлей

| 4540.71062933 8144.0831075 4553.2068654 6022.4028907 8131.58687142 14280.18669076  
10255.64588979 14205.35983138 18286.90153568 5371.09304426 18263.2941885 8649.05149051  
16087.35320687 6034.89912677 8812.52634749 12405.9018368 12175.45919904 15779.49412827  
12581.87292984 12115.71815718 6828.93706715 8370.31014755 15900.27100271 6970.34025896




Рис. 1: описание




Рис. 2: описание




Рис. 3: описание




Рис. 4: описание






Рис. 5: описание




Рис. 6: описание




Рис. 7: описание




Рис. 8: описание

21834.2366757 21888.52755194 17697.2899729 23103.55314664 11047.0340259 8112.37579042  
5419.84342066 17513.7910268 8338.03071364 9806.47395363 10317.9765131 8302.92080699  
12539.86750979 12667.05811503 11071.57482686 9806.80517916 9129.90063234 8324.72146944  
23230.35230352 9033.66455887 19058.56669678 18326.88949112 8345.13700693 11065.10087323  
11612.19512195 15410.14754592 8105.32971996 11558.3860283 9947.21469437 15839.23517013  
15456.85034628 19127.55194219 19097.71153267 9886.35953026 8741.82475158 19134.02589581  
8720.11442337 6358.8678109 7007.73863294 6242.63775971 8525.77536886 10274.16440831  
18218.33785005 7008.76242096 8570.1897019 9619.42186089 8421.28876844 9556.30834086  
7848.0277025 11098.79554351 10113.52002409 7881.48148148]

[ 4512.08490128 8136.68882728 4536.68882728 5959.03928906 8112.08490128 14029.88966967  
10036.60528191 14052.96206684 18029.88966967 5200. 18052.96206684 8792.90861544  
15783.93544201 5983.64321507 8795.55518251 12504.99351672 12107.2599948 15834.45077159  
12532.24400979 12069.93583775 6886.7544291 8385.73313842 15804.36127212 6850.67545945  
21733.25998256 21817.60684302 17723.841318 23113.63053782 11052.13077295 8100. 5300.  
17604.01391743 8370.07028832 9771.92746814 9988.92895873 8404.42879636 12306.67557023  
12393.35775509 11106.64224491 9817.74155953 9030.17512727 8392.94868855 23190.37500696  
9082.20985975 19050.5836368 18383.70846818 8411.73844409 11079.56056485 11646.70956579  
15353.51494397 8100. 11627.11114719 9926.05973381 15871.77492864 15426.54846013  
19046.25494916 19084.77372322 9906.4613152 8717.24144288 19056.61262238 8731.8331107  
6316.66727304 7000. 6241.61661408 8610.8049153 10303.46328863 18378.29758338 7000.  
8586.79601559 9653.88025171 8386.72804746 9624.4604672 7889.86114114 11093.32442977  
10252.42152938 7854.22071554]