

Восстановление матриц корреспонденций

Илья Забара¹, Евгений Ильин², Николай Моргунов¹, Леонид Переверзин³

¹ МФТИ, ФПМИ, М05-404Г

² МФТИ, ФПМИ, М05-401В

³ МФТИ, ФПМИ, М05-401А

Аннотация

Ставится bi-level задача о восстановлении матрицы корреспонденции по наблюдаемым потокам на ребрах транспортной сети. Приводится численный метод решения задачи оптимизации, основанный на методе зеркального спуска с проекциями на множество матриц, удовлетворяющих маргиналиям. Критерием качества восстановления матрицы корреспонденции является то, насколько хорошо она восстанавливает потоки на ребрах по равновесной модели Бэкмана. Приводится небольшое исследование качества восстановления матрицы в зависимости от количества наблюдаемых потоков на рёбрах (от количества датчиков), а так же от положения датчиков на графе.

Содержание

1	Используемые обозначения	3
2	Постановка задачи двухуровневой оптимизации	3
3	Численный алгоритм	3
3.1	Модель Бэкмана	3
3.2	Метод Франк—Вульфа	4
3.3	Зеркальный спуск с проекцией на пространство матриц корреспонденций в энтропийной геометрии	4
3.3.1	Почему именно KL-геометрия для зеркального спуска	4
3.3.2	Энтропийный зеркальный шаг (мультипликативное обновление) . . .	5
3.3.3	Проекция на маргиналии (IPF / iterative proportional fitting)	5
3.3.4	Выбор шага: бэктрекинг	5
3.4	Расчет градиента потоков по матрице корреспонденции	5
4	Генерация синтетических наблюдений потоков	6
4.1	Генерация референсных значений для функционала оптимизации	6
4.2	Выбор начального приближения для зеркального спуска	6
5	Численные эксперименты	7
5.1	Гиперпараметры алгоритма	7
5.2	Референсная матрица D_{ref} совпадает с D_{true}	7
5.2.1	Вариация количества наблюдаемых потоков на случайных рёбрах . .	7
5.2.2	Вариация выбора конкретных рёбер для лучшего качества восстановления	9
5.3	Референсная матрица D_{ref} не совпадает с D_{true}	10
5.3.1	Вариация выбора топ p рёбер для лучшего качества восстановления .	10
5.3.2	Расчет по рёбрам с 10% максимальными потоками	11
5.4	Вопросы без ответа и идеи	13

1 Используемые обозначения

Далее в тексте термины “OD-матрица”, “матрица спроса” и “матрица корреспонденции” обозначают одно и то же.

Транспортная сеть моделируется ориентированным графом $G = (V, E)$ на $|V| = n$ вершинах (зоны совпадают с вершинами), с числом рёбер $|E| = m$ из данных сети. Используются следующие обозначения:

- n — число зон (в эксперименте каждая зона соответствует вершине графа).
- m — число рёбер.
- $D \in \mathbb{R}_+^{n \times n}$ — OD-матрица спроса, $D_{ij} \geq 0, D_{ii} = 0$.
- Маргиналии (исходящие/входящие):

$$L_i = \sum_{j=1}^n D_{ij}, \quad W_j = \sum_{i=1}^n D_{ij}.$$

- Вектор потоков на рёбрах: $f \in \mathbb{R}_+^m$.
- Маска наблюдений потоков: $M \in \{0, 1\}^m$, $M_e = 1$ означает, что поток на ребре e наблюдается. Поэлементное умножение обозначим $\odot$.

Множество допустимых OD-матриц с фиксированными маргиналиями:

$$\mathcal{D}(L, W) = \{D \in \mathbb{R}_+^{n \times n} : D\mathbf{1} = L, D^\top \mathbf{1} = W, D_{ii} = 0\}.$$

Каждому ребру $e \in E$ сопоставляется **стоимость ребра** (далее используется используется BPR):

$$t_e(x_e) = t_e^0 \left(1 + \alpha_e \left(\frac{f_e}{c_e} \right)^{\beta_e} \right),$$

где f_e — поток на ребре e , $c_e > 0$ — пропускная способность, $t_e^0 > 0$ — время свободного проезда, $\alpha_e = 0.15$, $\beta_e = 4$ (в эксперименте одинаковы для всех рёбер).

2 Постановка задачи двухуровневой оптимизации

Ищется $D \in \mathcal{D}(L, W)$, минимизирующая расхождение модельных и наблюдаемых потоков на наблюдаемых рёбрах, плюс L_1 -регуляризация:

$$\min_{D \in \mathcal{D}(L, W)} \underbrace{\frac{1}{2} \|M \odot (f(D) - \hat{f})\|_2^2}_{\text{невязка по потокам}} + \lambda \underbrace{\|D - \hat{D}\|_1}_{\text{регуляризация}},$$

где $\lambda \geq 0$ — вес регуляризации, $\hat{f}$ — экспериментальные значения потоков, $\hat{D}$ — априорная матрица корреспонденции (может быть получена по модели или экспериментально), $f(D)$ — решение задачи Бэкмана о равновесном распределении нагрузки на транспортную сеть.

3 Численный алгоритм

3.1 Модель Бэкмана

Для фиксированного спроса D потоки $f(D)$ определяются как решение задачи равновесного назначения (Wardrop UE), которая в случае с приведённой $t_e(f)$ может быть переписана в терминах минимизации потенциала:

$$\min_{f \in \mathcal{F}(D)} \Phi(f) = \sum_{e \in E} \int_0^{f_e} t_e(s) ds,$$

где $\mathcal{F}(D)$ — множество потоков, реализуемых некоторым разбиением спроса D по путям (стандартные ограничения сохранения потоков/спроса).

Градиент потенциала по потокам имеет простой вид:

$$\nabla_f \Phi(f) = t(f) \in \mathbb{R}^m, \quad [t(f)]_e = t_e(f_e).$$

3.2 Метод Франк—Вульфа

1. Инициализация: $f^{(0)}$ = распределение потоков по полю стоимости t_e^0 (то есть в ненагруженной сети).
2. На итерации k :
 - вычисляются текущие времена $t^{(k)} = t(f^{(k)})$;
 - решается линейная подзадача

$$y^{(k)} \in \arg \min_{y \in \mathcal{F}(D)} \langle t^{(k)}, y \rangle,$$

что можно переформулировать как “для каждого origin o весь спрос D_o отправляется по кратчайшим путям (по весам $t^{(k)}$) к каждому destination d ”

- обновления состояния:

$$f^{(k+1)} = (1 - \gamma_k) f^{(k)} + \gamma_k y^{(k)}, \quad \gamma_k = \frac{2}{k+2}.$$

Итоговая аппроксимация равновесного потока:

$$f(D) \approx f^{(K)},$$

где K — это гиперпараметр числа итераций.

3.3 Зеркальный спуск с проекцией на пространство матриц корреспонденций в энтропийной геометрии

Оптимизация ведётся на множестве $\mathcal{D}(L, W)$, а ограничение по маргиналиям реализуется через **энтропийную геометрию**: зеркальный шаг делается в терминах дивергенции Кульбака—Лейблера (KL). Важно: KL здесь — это **геометрия проекции зеркального спуска**, а не отдельная регуляризация в функционале.

3.3.1 Почему именно KL-геометрия для зеркального спуска

Переменная D должна оставаться **неотрицательной** и одновременно удовлетворять **линейным ограничениям на маргиналии**. Для таких задач (положительный ортант / симплексоподобные множества и транспортные планы) энтропийная геометрия является естественным выбором по двум причинам:

1) Неотрицательность:

Энтропийный зеркальный шаг (exponentiated gradient) имеет вид $D \mapsto D \odot \exp(-\eta G)$ и сохраняет $D_{ij} \geq 0$ (в отличие от обычного аддитивного шага градиентного спуска, который легко даёт отрицательные значения и требует дополнительных хаков).

2) Проекция на маргиналии вычисляется эффективно:

KL-проекция на множество матриц с фиксированными суммами строк/столбцов сводится к IPF (попеременное масштабирование строк/столбцов). Евклидова проекция на то же множество, как правило, существенно дороже (это отдельная квадратичная задача с большим числом ограничений) и хуже сочетается с требованием неотрицательности.

Формально, зеркальный шаг можно понимать как решение подзадачи

$$D^{(k+1)} \in \arg \min_{D \in \mathcal{D}(L, W)} \left\{ \langle G^{(k)}, D \rangle + \frac{1}{\eta_k} \text{KL}(D \| D^{(k)}) \right\},$$

то есть мы “минимально” (в KL-смысле) меняем $D^{(k)}$, чтобы спуститься по (суб)градиенту и остаться в допустимом множестве.

3.3.2 Энтروпийный зеркальный шаг (мультипликативное обновление)

Пусть $G^{(k)} \in \partial_D \mathcal{L}(D^{(k)})$ — (приближённый) градиент/субградиент на итерации k и $\eta_k > 0$ — шаг. Для L1-слагаемого можно взять субградиент

$$\partial_D \|D - \hat{D}\|_1 = \text{sign}(D - \hat{D})$$

(с нулями на диагонали).

Тогда энтропийное зеркальное обновление (exponentiated gradient) имеет поэлементный вид

$$\widetilde{D}_{ij}^{(k+1)} = D_{ij}^{(k)} \exp(-\eta_k G_{ij}^{(k)}), \quad i \neq j,$$

и $\widetilde{D}_{ii}^{(k+1)} = 0$.

3.3.3 Проекция на маргиналии (IPF / iterative proportional fitting)

После мультипликативного шага выполняется та же проекция на $\mathcal{D}(L, W)$ в KL-метрике, которая для матриц с фиксированными маргиналиями реализуется, как уже было сказано, через IPF (попеременное масштабирование строк и столбцов):

Инициализация: $D \leftarrow \widetilde{D}$, $D_{ii} = 0$.

Далее повторять T раз:

1) масштабирование строк:

$$D_{ij} \leftarrow D_{ij} \cdot \frac{L_i}{\sum_j D_{ij}},$$

2) масштабирование столбцов:

$$D_{ij} \leftarrow D_{ij} \cdot \frac{W_j}{\sum_i D_{ij}},$$

и после каждого шага обнулять диагональ.

Результат принимается как $D^{(k+1)}$.

3.3.4 Выбор шага: бэктрекинг

Шаг η_k выбирается бэктрекингом: стартуя с некоторого η_0 , уменьшаем шаг $\eta \leftarrow \beta \eta$ (где $\beta \in (0, 1)$), пока не выполнится убывание цели

$$\mathcal{L}(D_{\text{cand}}) < \mathcal{L}(D^{(k)}) - \varepsilon_{\text{imp}}.$$

3.4 Расчет градиента потоков по матрице корреспонденции

Обозначим невязку на наблюдаемых рёбрах:

$$r(D) = M \odot (f(D) - \hat{f}) \in \mathbb{R}^m.$$

Тогда градиент квадрата невязки потоков по матрице D , вытянутой в вектор, выражается через Якобиан

$$J(D) = \frac{\partial f(D)}{\partial \text{vec}(D)} \in \mathbb{R}^{m \times n^2} : \quad \nabla_D \frac{1}{2} \|r(D)\|_2^2 = \text{unvec}(J(D)^\top r(D)).$$

Мы будем приближать $J(D)$ при помощи рекурсивной формулы, которая следует из алгоритма решения задачи Бэкмана – метода Франк-Вульфа.

При фиксированных весах $t^{(k)}$ нагрузка на каждой итерации метода линейна по D (так как решается задача ЛП на множестве). Тогда можно представить зависимость потоков от матрицы корреспонденции как:

$$f^{(k)} = A(t^{(k)}) \text{vec}(D),$$

где матрица маршрутизации $A(t^{(k)})$ имеет элементы

$$[A(t^{(k)})]_{e,(o,d)} = \begin{cases} 1, & \text{если ребро } e \text{ лежит на выбранном кратчайшем пути } o \rightarrow d \text{ при весах } t^{(k)}, \\ 0, & \text{иначе.} \end{cases}$$

Если рассматривать веса $t^{(k)}$ как «замороженные», то Якобиан итерации метода удовлетворяет рекурсии:

$$\begin{aligned} G^{(0)} &= 0, & G^{(k+1)} &= (1 - \gamma_k)G^{(k)} + \gamma_k A(t^{(k)}), \\ J(D) &\approx G^{(K)}, & \nabla_D \frac{1}{2} \|r\|^2 &\approx \text{unvec}((G^{(K)})^\top r). \end{aligned}$$

Замечание: такой вывод имеет место быть, если при заданной нагрузке $t_e(f(D^k))$ при всех k не существует двух кратчайших путей на графе сети (то есть с одинаковой стоимостью). Если такое всё же имеет место, то функция становится не дифференцируемой. Все же предполагается, что вектор, получаемый до заданному алгоритму является элементом субдифференциала даже в такой точке.

4 Генерация синтетических наблюдений потоков

Пусть задана «истинная» матрица корреспонденций D_{true} .

4.1 Генерация референсных значений для функционала оптимизации

$$\hat{f} = f(D_{\text{true}}), \quad \hat{D} = \text{proj}(D_{\text{true}} * (1 + \xi)),$$

где ξ – некоторая случайная матрица, моделирующая шум в данных или неточность модели, по которой строится референс $\hat{D}$, а $\text{proj}(\cdot)$ – проекция на маргиналии.

4.2 Выбор начального приближения для зеркального спуска

Стартовая точка $D^{(0)}$ строится из референса D_{ref} через SVD и эвристическую модификацию сингулярных значений. Это сделано с целью контролируемого изменения точности начального приближения (это удобно для проведения экспериментов).

$$D_{\text{ref}} = U \text{diag}(\sigma) V^\top, \quad \tilde{D} = U \text{diag}(\tilde{\sigma}) V^\top,$$

где $\tilde{\sigma}$ получается из σ некоторой модификацией (в экспериментах заменяется главное сингулярное число).

Далее $\tilde{D}$ приводится в допустимое множество: $D^{(0)} = \text{proj}(\max(\tilde{D}, 0))$, то есть выполняется проекция на заданные маргиналии (L, W) методом IPF с обнулением диагонали.

5 Численные эксперименты

Численные эксперименты проводились на графе и матрицы корреспонденции SiouxFalls. Данные расположены по ссылке (SiouxFalls).

5.1 Гиперпараметры алгоритма

- **Наблюдения потоков:** доля наблюдаемых рёбер p ; зерно генерации маски M ; уровень шума σ и зерно генерации шума.
- **Регуляризация:** вес λ у L1-регуляризатора $\|D - D_{\text{true}}\|_1$ (в большинстве запусков используется $\lambda = 5 \cdot 10^2$).
- **Метод Франк-Вульфа:** максимум итераций $K = 200$; убывающий шаг $\gamma_k = 2/(k + 2)$.
- **Зеркальный спуск:** число внешних итераций (используется разное кол-во); максимум итераций бектрекинга 50; IPF-проекция имеет не более $T = 30$ внутренних итераций.

5.2 Референсная матрица D_{ref} совпадает с D_{true}

В текущем эксперименте предполагалось, что $\hat{D} = D_{\text{true}}$. При этом так как потоки $\hat{f} = f(D_{\text{true}})$, то решением задачи является $D = D_{\text{true}}$. В данном эксперименте проверяется сходимость к этому значению. Стоит сразу оговориться, что функция, которую мы оптимизируем не является выпуклой, и метод находит некоторый локальный минимум, в котором и застревает. Численные эксперименты показали, что несмотря на это качество матрицы корреспонденции остается приемлемым.

5.2.1 Вариация количества наблюдаемых потоков на случайных рёбрах

В данном эксперименте изменялось количество наблюдаемых потоков (формально: изменялось количество нулей и единиц в маске M). При этом выбор потоков, на который смотрим был случайным, но таким, что выполнение включения маски с меньшим количеством потоков в маску с большим количеством потоков (то есть маски “расширяются”). Ниже приведены графики для относительной разницы потоков и матрицы корреспонденции с соответствующими референсами.




Рис. 1: Относительная ошибка потоков (случайные наблюдаемые рёбра)




Рис. 2: Относительная ошибка восстановления матрицы (случайные наблюдаемые рёбра)

На графиках видна тенденция: чем больше поток наблюдается, тем лучше качество восстановления матрицы корреляции. При этом сама матрица (в терминах L_1 нормы) восстанавливается хуже.

5.2.2 Вариация выбора конкретных рёбер для лучшего качества восстановления

В данном эксперименте исследовалась зависимость качества восстановления матрицы корреспонденции от тех рёбер, на которых компоненты $\hat{f}$ считались известными. Сравнивались три сценария: 50% максимальных по модулю компонент, 50% минимальных по модулю компонент и 50% случайных компонент вектора $\hat{f}$. Ниже приведены графики сравнения качества восстановления матрицы.




Рис. 3: Относительная ошибка потоков (выбор наблюдаемых рёбер по модулю потоков)




Рис. 4: Относительная ошибка восстановления матрицы (выбор наблюдаемых рёбер по модулю потоков)

Из графика видна тенденция: чем больше компоненты наблюдаемых потоков, тем лучше точность восстановления.

5.3 Референсная матрица D_{ref} не совпадает с D_{true}

Теперь зашумим референсную матрицу D_{ref} на 20% относительно D_{true} .

5.3.1 Вариация выбора топ p рёбер для лучшего качества восстановления

В данном эксперименте выбираются различные количества индексов с максимальными по модулями компонентами в вектора $\hat{f}$.




Рис. 5: Относительная ошибка потоков (зашумлённый D_{ref} , топ p рёбер)




Рис. 6: Относительная ошибка восстановления матрицы (зашумлённый D_{ref} , топ p рёбер)

Этот график подтверждает выводы пункта 5.2.1.

5.3.2 Расчет по рёбрам с 10% максимальными потоками

Теперь проведем “боевой эксперимент”. Начальное приближение не генерировалось с помощью сингулярного разложения, а бралось в виде $D^0 = D_{true} * (1 + noise)$. В данном экспери-

ремне относительная $L1$ норма относительно D_{true} была 0.2. Матрицы D_{ref} относительно также зашумлялась, относительная ошибка была 0.2. Графики сходимости приведены ниже.




Рис. 7: Относительная ошибка потоков (top 10% рёбер, шум в D^0 и D_{ref})




Рис. 8: Относительная ошибка восстановления матрицы (top 10% рёбер, шум в D^0 и D_{ref})

На таких данных алгоритм дает восстановление потоков (а значит и качество матрицы) на уровне 0.015.

5.4 Вопросы без ответа и идеи

1. Какое качество будет у матрицы на построенной по какой-либо модели (гравитационная, энтропийная). Будет ли оно уже достаточно хорошим? И нужна ли вообще оптимизация тогда?
2. Вывод рекурсии для градиента не является верным даже в точке, где функция дифференцируема, если функциональная последовательность, генерируемая методом Франк-Вульфа не является равномерно сходящейся. Это не исследовалось, но ощущение есть, что все же она не равномерно сходится...
3. Если в алгоритме отключить регуляризацию вовсе, то результатом будет некоторая матрица, которая отличается от исходной на 0.8 по относительной ошибке, при этом точность восстановления потоков около 0.05 при использовании 50% потоков. Это победа?